Практическая применимость проекта «Детекция дипфейков на фото лиц»

Годовой проект №35, магистратура «Искусственный интеллект», НИУ ВШЭ. Команда: Д. Маслов, А. Валиев, Г. Лазовская, А. Устамчук. Куратор: И. Скворцов.

1. Где применяется и чью проблему решает

Фото лица подтверждает личность в банках при удалённой идентификации, на маркетплейсах при проверке продавцов, при удалённом найме и в модерации соцсетей. Сгенерированное или подменённое лицо можно выдать за настоящее, а ручная проверка дорогая. Наш сервис принимает фото и возвращает одно из трёх состояний: «обнаружены признаки подделки», «не обнаружены», «недостаточно данных» (нет лица, лицо меньше 32 px, профиль, сильное сжатие), а также версию модели и порог. Окончательное решение принимает модератор.

2. Насколько это реалистично

Внутри одного датасета задача почти решена: на OpenForensics дообученная ResNet-18 даёт ROC-AUC 0,995 и ловит 90–96 подделок из 100 при 1% ложных тревог. На чужих генераторах сеть пока не проверена, а наш простой FFT-бейзлайн, обученный на 140k, на фейках OpenForensics даёт ROC-AUC 0,563, почти наугад. Значит, главный вопрос – перенос на новые генераторы, и с ним связана большая часть трудностей ниже.

3. Трудности и насколько они серьёзны

Числа – из EDA команды по четырём датасетам: 140k Real and Fake Faces (лица StyleGAN), OpenForensics (подмена лиц на фото из жизни), DF40 (40 методов генерации и редактирования лиц), MFFI (50 методов подделки).

Трудность	Что показал EDA	Насколько серьёзно	Что делаем
Новые генераторы, данные быстро устаревают	FFT-бейзлайн, обученный на 140k, на чужом генераторе даёт ROC-AUC 0,563	высокая: на подделках новых генераторов сервис почти бесполезен	тест на незнакомых генераторах (DF40, MFFI) и живой тест (раздел 4)
Шорткаты в данных	140k: поза и кадрирование лица дают ROC-AUC 0,73 без следов подделки; OpenForensics: размер лица в кропе по разметке – 0,82–0,85; DF40: формат PNG только у fake; в общем датасете доля fake зависит от источника (50–99%)	высокая: модель выглядит точной, но ловит не подделку	кроп по детектору лиц, балансировка, проверка на test без шортката
Копии одного фото	140k: у 31–32% fake в valid/test есть почти-копия в train; OpenForensics: копии у 70% кадров (внутри сплитов)	высокая: метрики завышены	деление по группам копий: в общем датасете 0 пересечений между сплитами
Сжатие при пересылке	140k: на JPEG 75 ложных тревог 8,0% вместо 1%	средняя: порог сбивается, но это лечится обучением	обучение со сжатием и уменьшением: 1,7–2,7% ложных тревог
Обход детектора (безопасность)	OpenForensics: после JPEG 50 модель ловит 60–65 подделок из 100 вместо 89–96, после уменьшения вдвое – 68–73	высокая: достаточно пересохранить фото	обучение со сжатием, масштабом и размытием (82–86 из 100 после JPEG 50), тест устойчивости
Неравное качество для разных людей (этика)	OpenForensics: на тёмных лицах ловим 74 подделки из 100, на крупных (от 256 px) – 83; профилей около 1%	средняя: часть людей проверяется хуже	качество по группам лиц; на профилях – «недостаточно данных»
Ложные обвинения (этика)	–	высокая: вред честному пользователю	порог при 1% ложных тревог, формулировка «признаки», решение за человеком

4. Как заказчик оценит качество

На своей отложенной выборке с известной разметкой, порог фиксируется заранее.

- Главная метрика – доля пойманных подделок при 1% ложных тревог (TPR @ FPR = 1%).
- Качество отдельно для каждого способа создания подделок (StyleGAN, диффузионные модели, подмена лица и т. д.) и для худшего из них: средняя цифра может скрыть провал на одном генераторе.
- Качество по группам лиц: размер, поза, освещение.
- Доля ложных тревог на настоящих сжатых фото и доля ответов «недостаточно данных».
- Живой тест: заказчик делает подделки свежими инструментами и проверяет их вместе со своими настоящими фото, снятыми в тех же условиях. Все загрузки приводятся к одному виду (JPEG, кроп по детектору), иначе модель различает формат, а не подделку.